Mask R-CNN v prostředí GRASS GIS

Ondřej Pešek

České vysoké učení technické v Praze
Fakulta stavební
Obor Geomatika

20. června 2018

Motivace
Teoretický úvod
Konvoluční neuronové sítě
Mask R-CNN
Implementace
Použití
i.ann.maskrcnn.train
i.ann.maskrcnn.detect
Výsledky
Závěr
Zdroje
Reakce na otázky oponenta

Obsah

Motivace

Teoretický úvod
- Konvoluční neuronové sítě
- Mask R-CNN

Implementace
- Použití
- i.ann.maskrcnn.train
- i.ann.maskrcnn.detect
- Výsledky

Závěr

Zdroje

Reakce na otázky oponenta

Motivace

Situace

- posilování satelitní sítě
- posilování leteckého snímkování
- vektorizace skenovaných map

Motivace

Situace

- posilování satelitní sítě
- posilování leteckého snímkování
- vektorizace skenovaných map
- zlepšování kvality snímků

Motivace
Teoretický úvod
Konvoluční neuronové sítě
Mask R-CNN
Implementace
Použití
i.ann.maskrcnn.train
i.ann.maskrcnn.detect
Výsledky
Závěr
Zdroje
Reakce na otázky oponenta

Motivace

Situace

- posilování satelitní sítě
- posilování leteckého snímkování
- vektorizace skenovaných map
- zlepšování kvality snímků
- otevírání dat

Motivace

Situace

- posilování satelitní sítě
- posilování leteckého snímkování
- vektorizace skenovaných map
- zlepšování kvality snímků
- otevírání dat
- standardizace dat

Motivace

Běžné způsoby klasifikace

- ruční klasifikace

GRASS GIS

- ruční klasifikace
  - GRASS Digitizing tool

Motivace

Běžné způsoby klasifikace

- ruční klasifikace
- řízená klasifikace

GRASS GIS

- ruční klasifikace
  - GRASS Digitizing tool
- řízená klasifikace
  - g.gui.iclass + i.maxlik
  - metoda maximální věrohodnosti

Motivace

Běžné způsoby klasifikace

- ruční klasifikace
- řízená klasifikace
- neřízená klasifikace

GRASS GIS

- ruční klasifikace
  - GRASS Digitizing tool
- řízená klasifikace
  - g.gui.iclass + i.maxlik
  - metoda maximální věrohodnosti
- neřízená klasifikace
  - i.cluster + i.maxlik
  - metoda maximální věrohodnosti

Motivace

Proč neuronové sítě?

- mozek je nejsilnější nástroj, který máme dispozici
- snažíme se dosáhnout lidsky srozumitelných výsledků

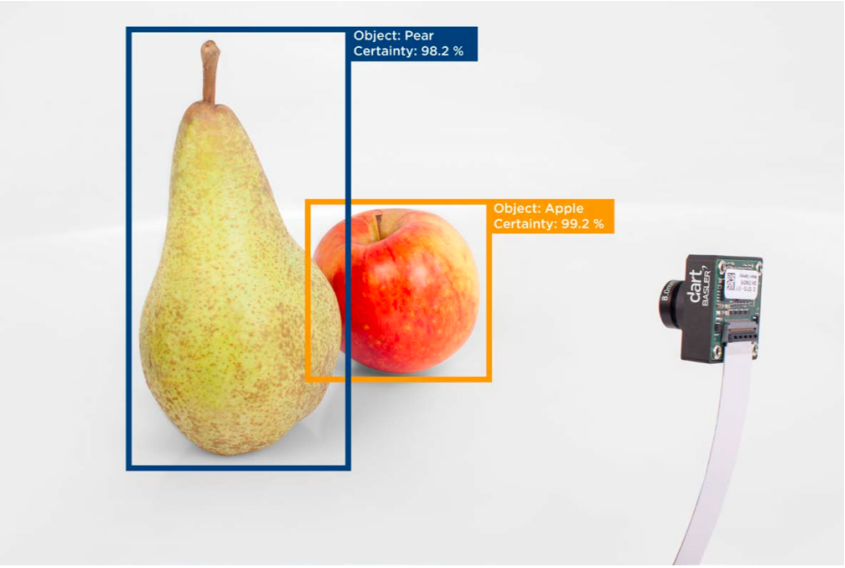

Obrázek: Zdroj: [1]

Motivace

Proč neuronové sítě?

- mozek je nejsilnější nástroj, který máme dispozici
- snažíme se dosáhnout lidsky srozumitelných výsledků

Obrázek: Zdroj: [1]

Motivace

Proč neuronové sítě?

- mozek je nejsilnější nástroj, který máme dispozici
- snažíme se dosáhnout lidsky srozumitelných výsledků

Obrázek: Zdroj: [1]

Konvoluční neuronové sítě

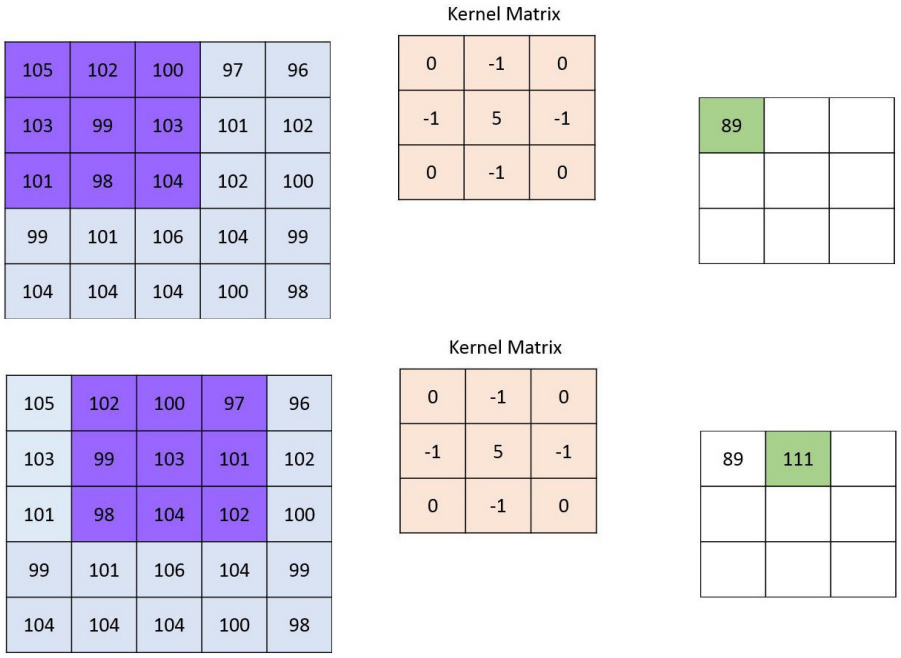

Konvoluční neuronové sítě

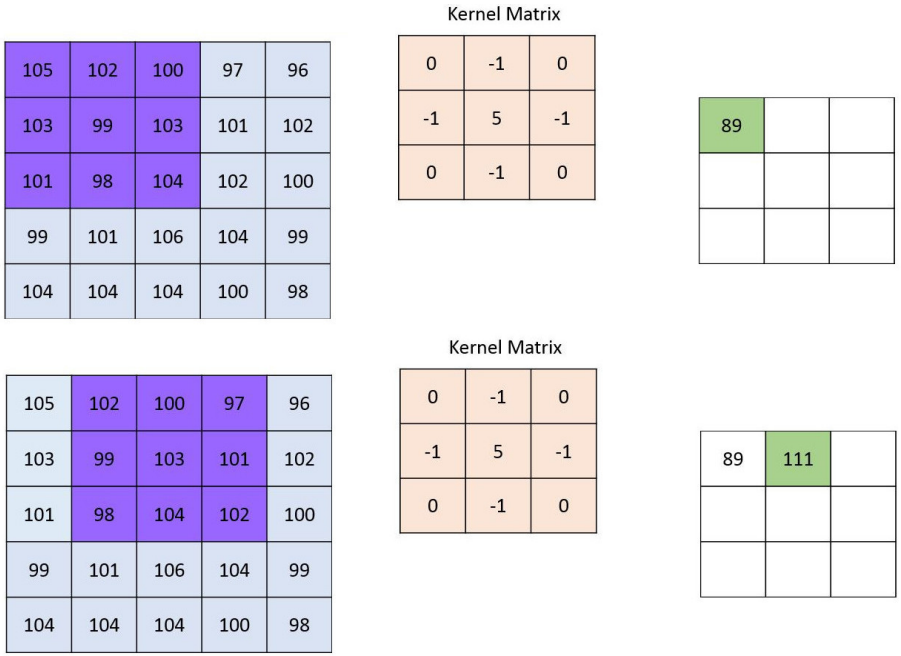

Proč konvoluční neuronové sítě?

- ResNet dosáhl v ILSVRC 2016 chybovosti 3.6 %

Zdroj: [2]

Konvoluční neuronové sítě

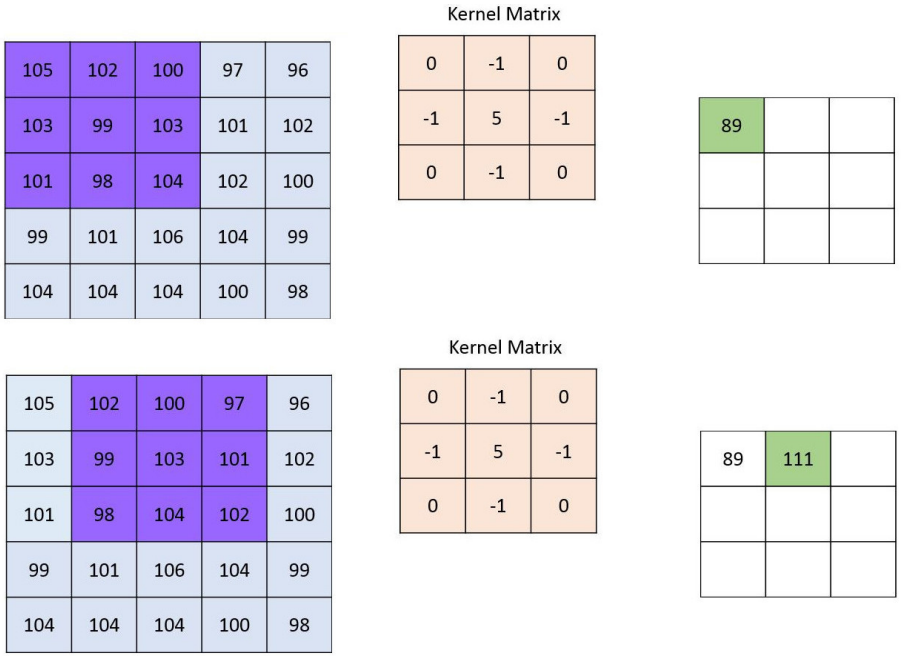

Proč konvoluční neuronové sítě?

- ResNet dosáhl v ILSVRC 2016 chybovosti 3.6 %
- člověk 8 %

Zdroj: [2]

Mask R-CNN

Instanční segmentace

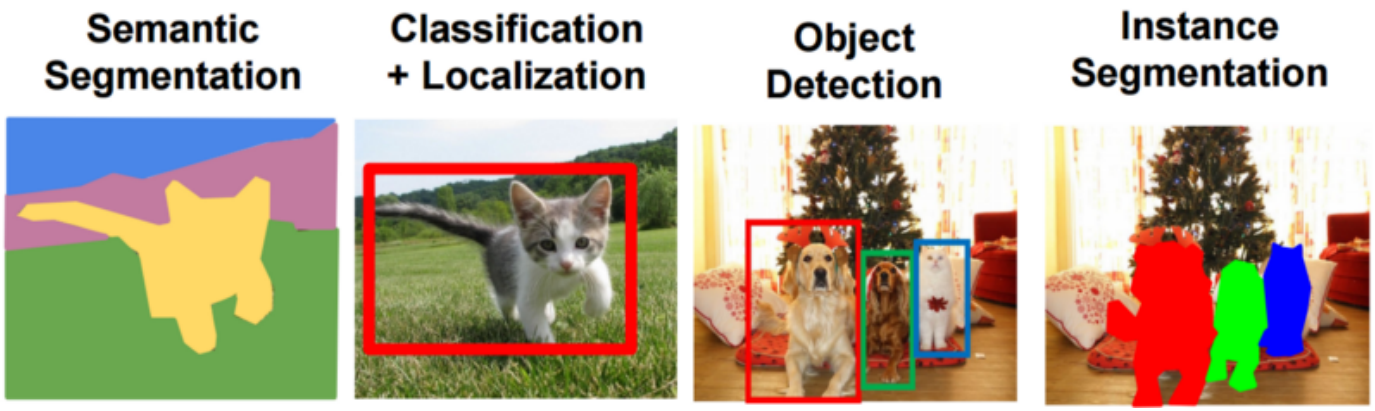

Obrázek: Zdroj: [3]

Mask R-CNN

Instanční segmentace

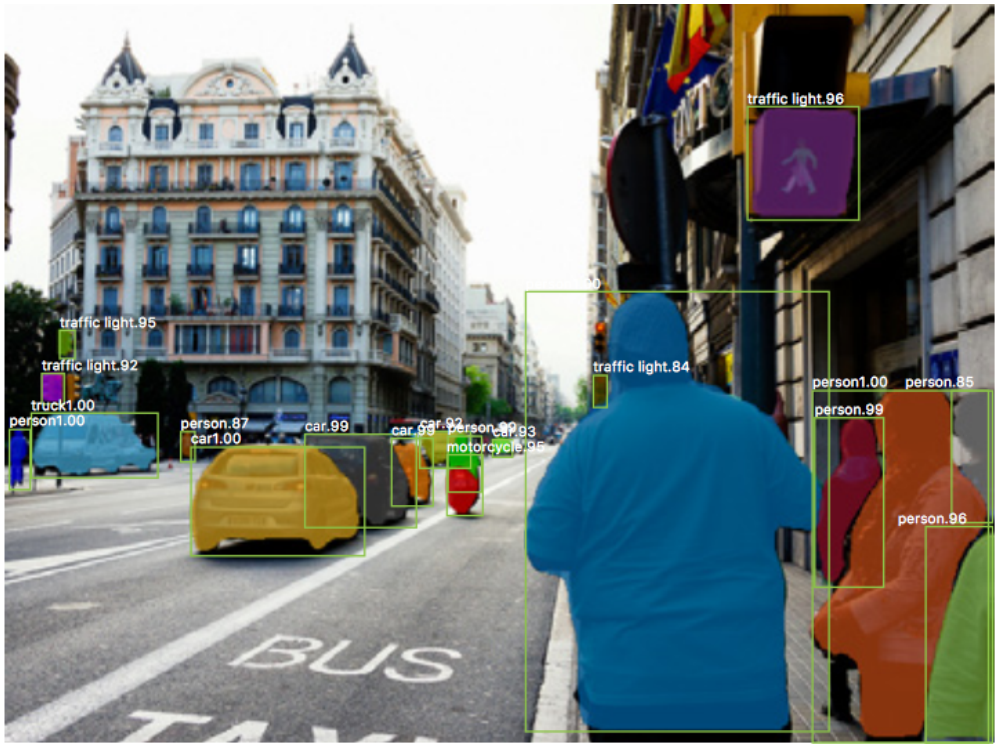

Obrázek: Zdroj: [3]

Mask R-CNN

Dvě části:

- páteřní
- hlavová

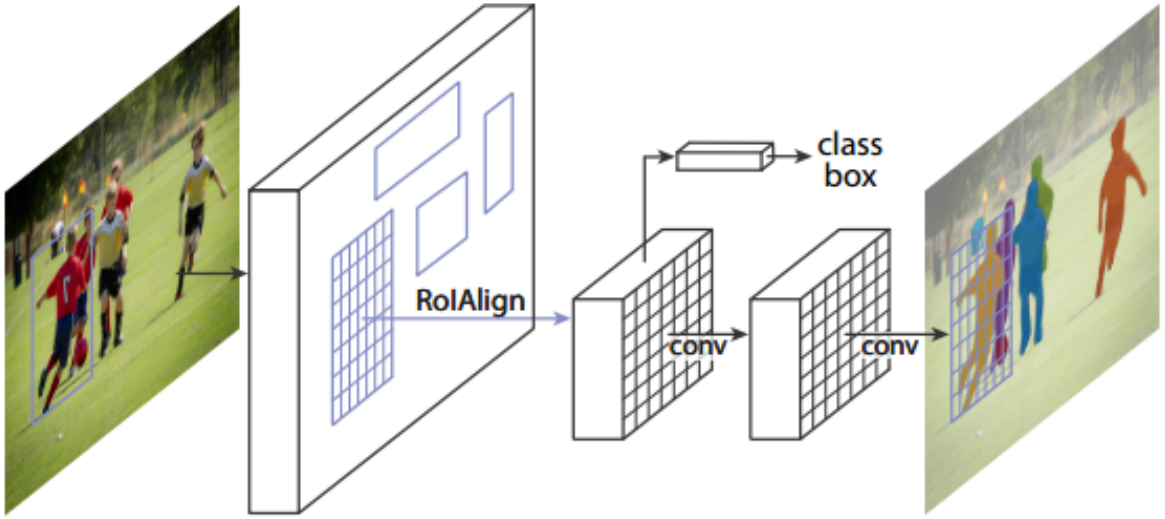

Obrázek: Zdroj: [4]

Mask R-CNN

Páteřní architektura:

- ResNet

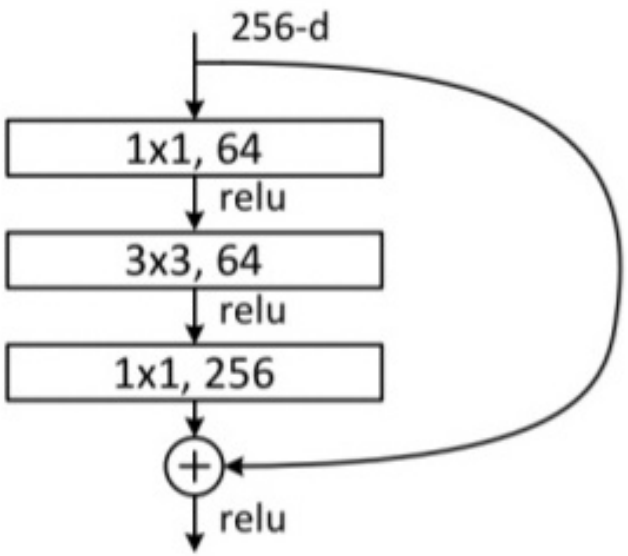

Obrázek: Zdroj: [4]

Mask R-CNN

Páteřní architektura:

- ResNet
- RPN

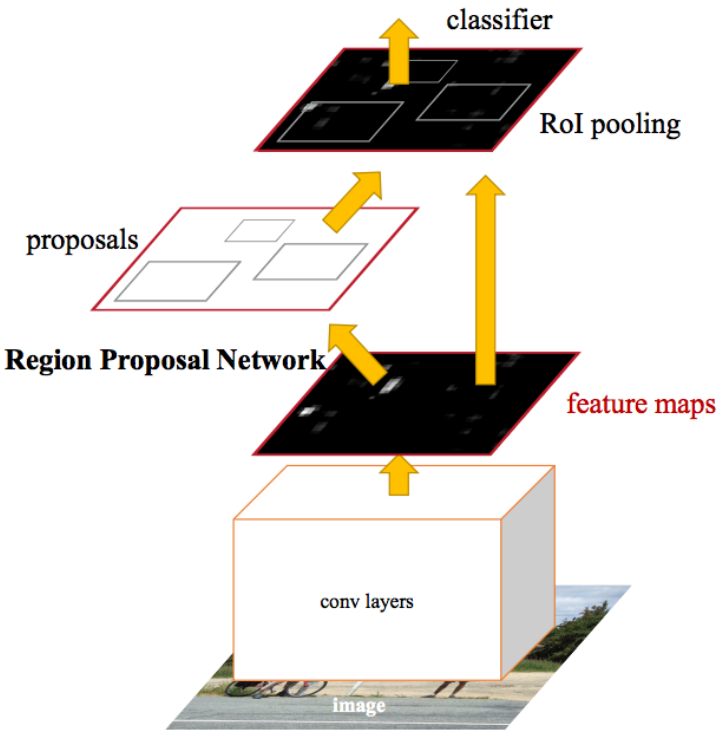

Obrázek: Zdroj: [4]

Mask R-CNN

Páteřní architektura:

- ResNet
- RPN

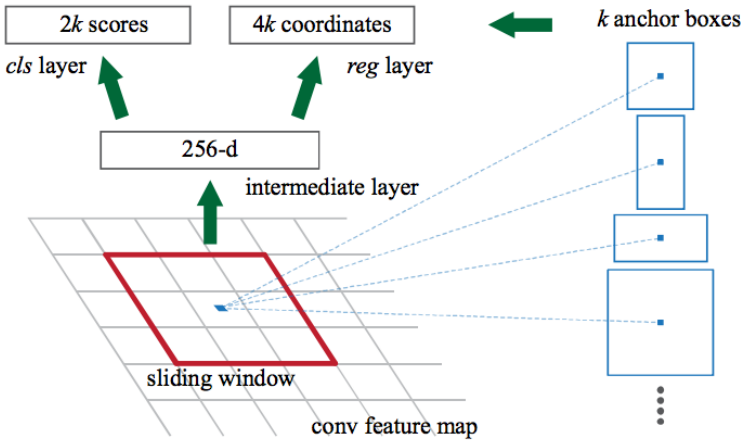

Obrázek: Zdroj: [4]

Mask R-CNN

Hlavová architektura:

- softmax → třída

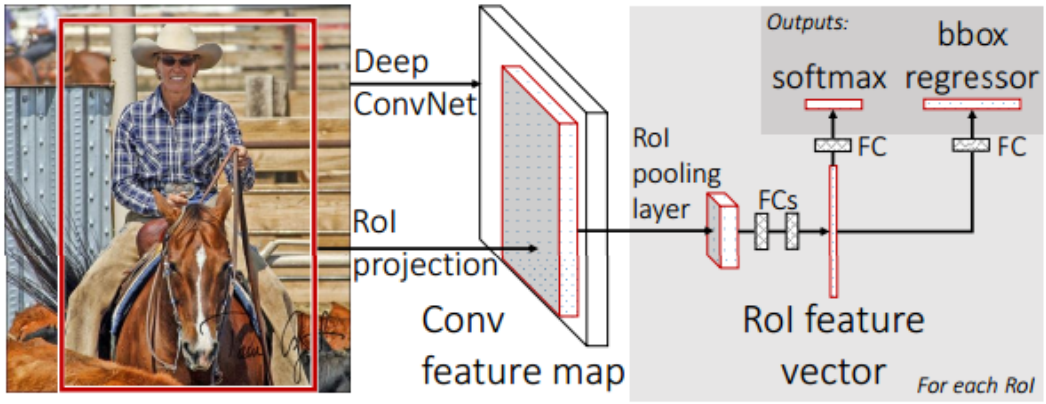

Obrázek: Zdroj: [5]

Motivace
Teoretický úvod
Konvoluční neuronové sítě
Mask R-CNN
Implementace
Použití
i.ann.maskrcnn.train
i.ann.maskrcnn.detect
Výsledky
Závěr
Zdroje
Reakce na otázky oponenta

Mask R-CNN

Hlavová architektura:

- softmax → třída
- regrese → ohraničující obdélník

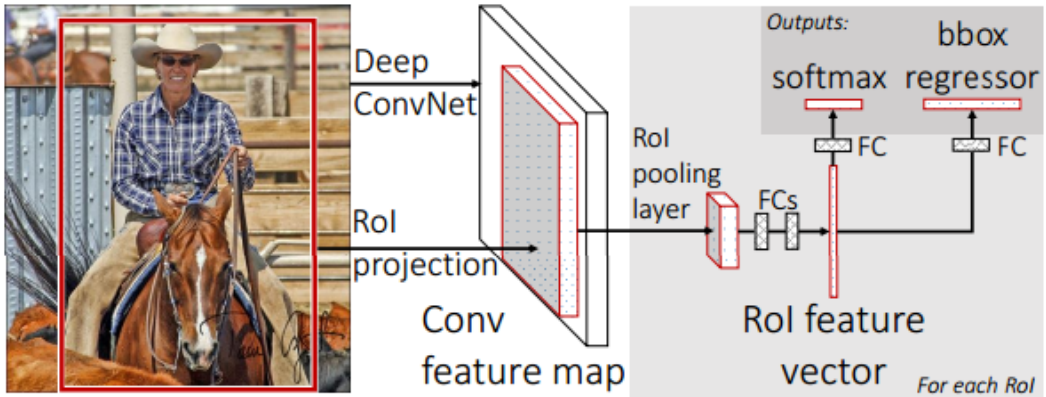

Obrázek: Zdroj: [5]

Motivace
Teoretický úvod
Konvoluční neuronové sítě
Mask R-CNN
Implementace
Použití
i.ann.maskrcnn.train
i.ann.maskrcnn.detect
Výsledky
Závěr
Zdroje
Reakce na otázky oponenta

Mask R-CNN

Hlavová architektura:

- softmax → třída
- regrese → ohraničující obdélník
- plně spojené vrstvy → maska

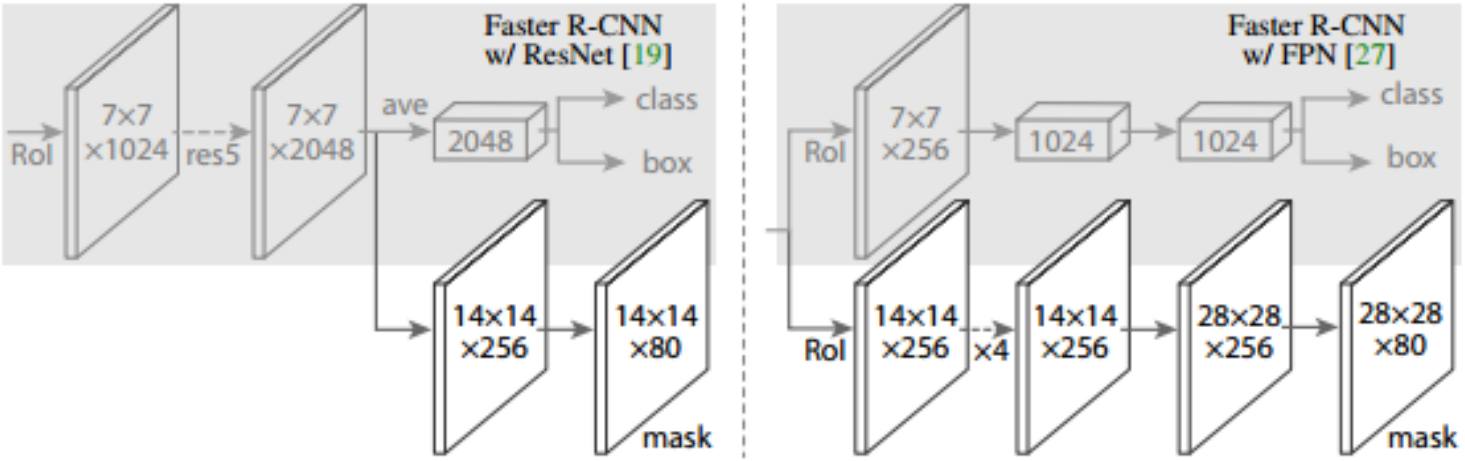

Obrázek: Zdroj: [5]

Použití

Postup práce:

- i.ann.maskrcnn.train
- i.ann.maskrcnn.detect

i.ann.maskrcnn.train

Postup práce modulu

- konfigurace modelu

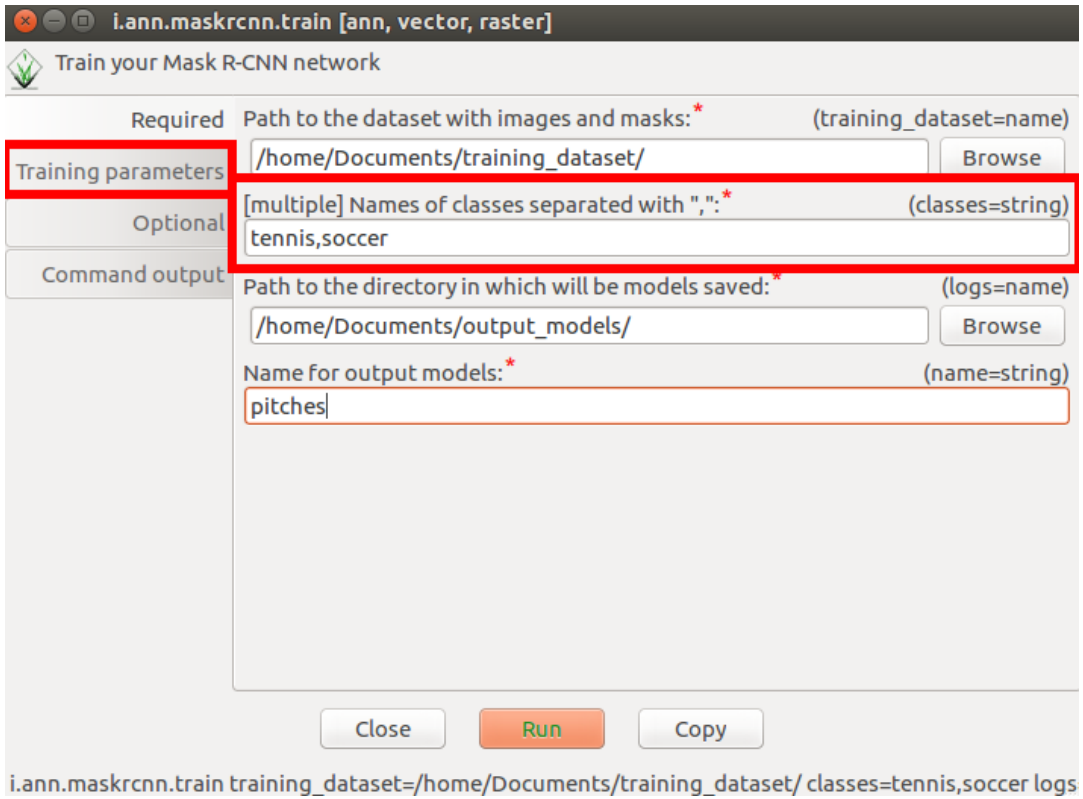

i.ann.maskrcnn.train

Postup práce modulu

- konfigurace modelu
- naplnění předtrénovanými váhami

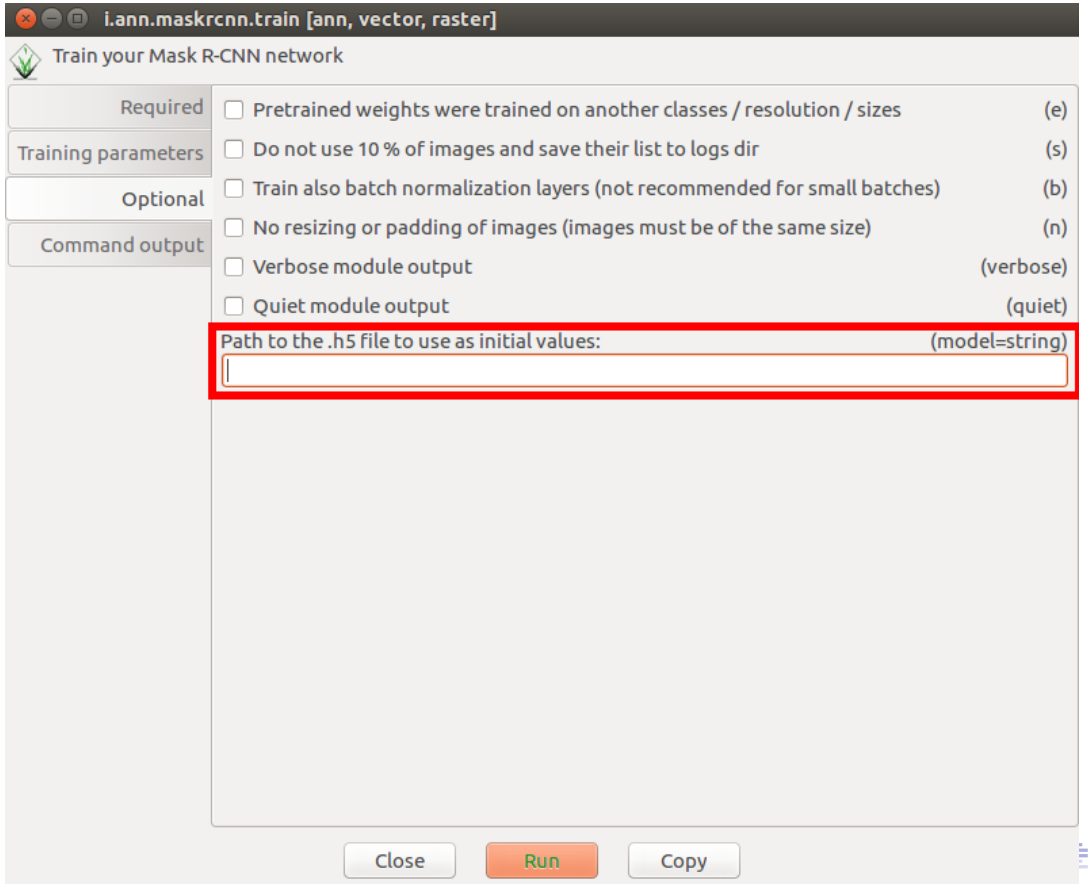

i.ann.maskrcnn.train

Postup práce modulu

- konfigurace modelu
- naplnění předtrénovanými váhami
- přečtení datasetu

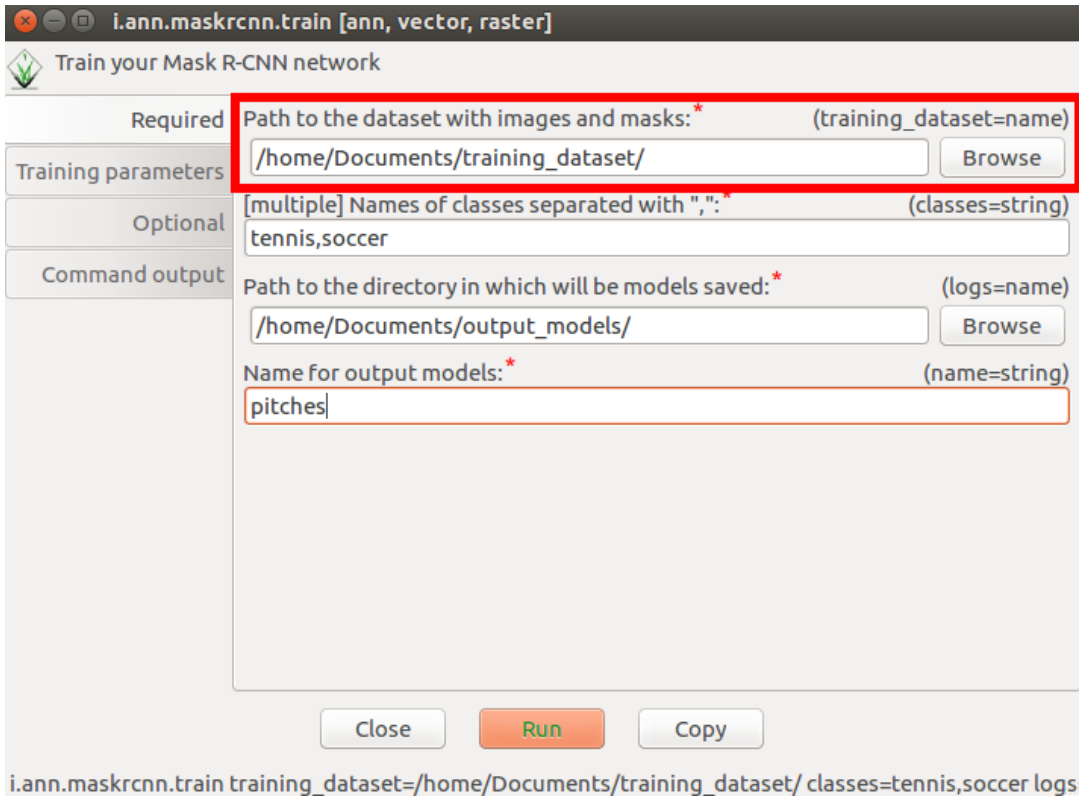

i.ann.maskrcnn.train

Postup práce modulu

- konfigurace modelu
- naplnění předtrénovanými váhami
- přečtení datasetu
- učení

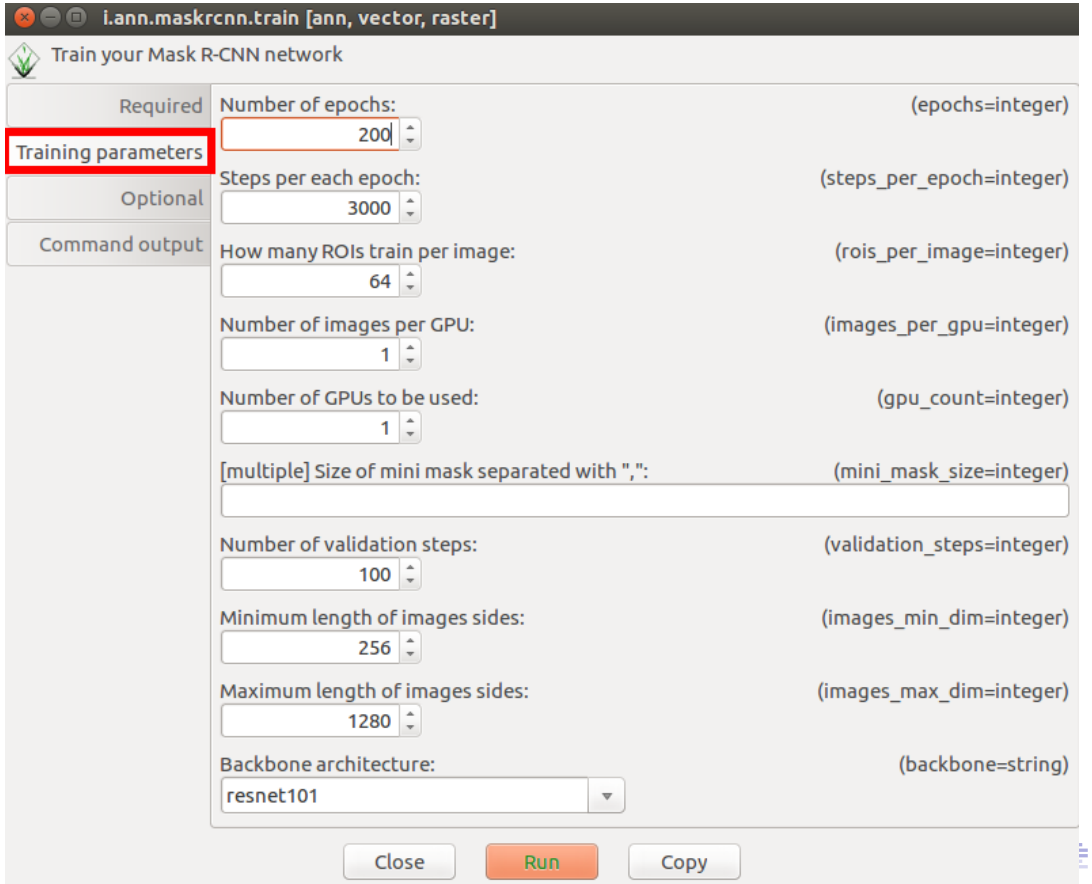

i.ann.maskrcnn.train

Postup práce modulu

- konfigurace modelu
- naplnění předtrénovanými váhami
- přečtení datasetu
- učení
- uložení modelu

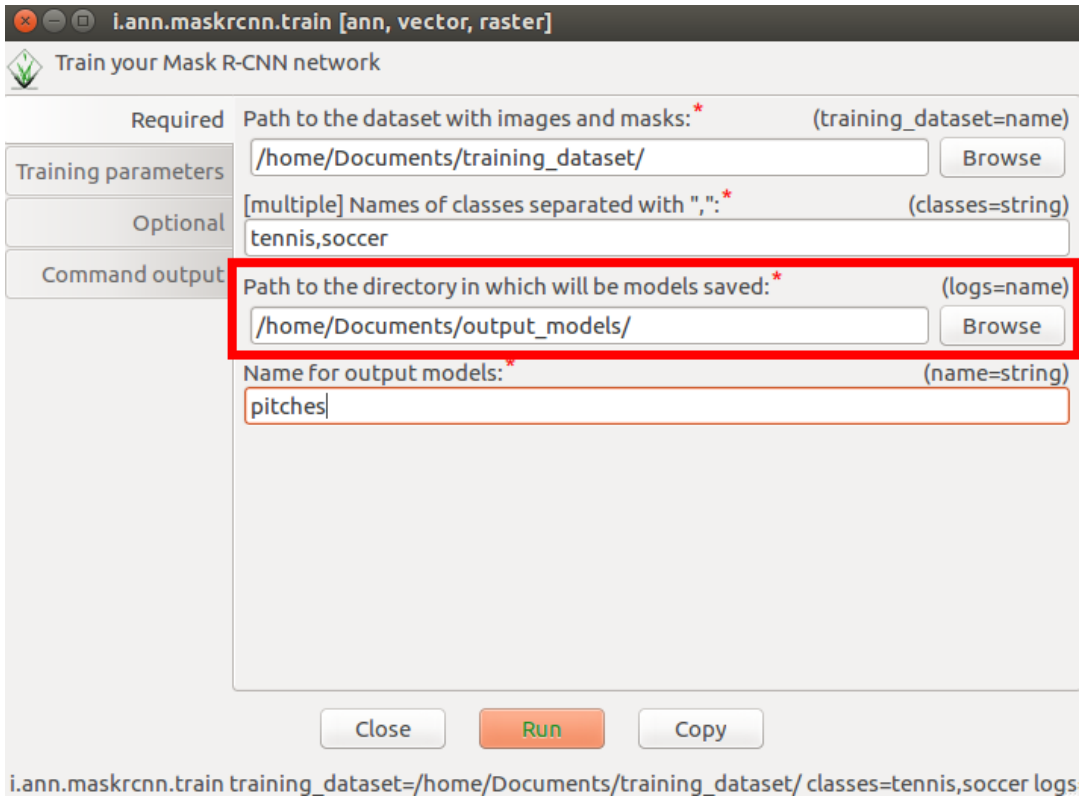

i.ann.maskrcnn.detect

Postup práce modulu

- naplnění natrénovanými váhami

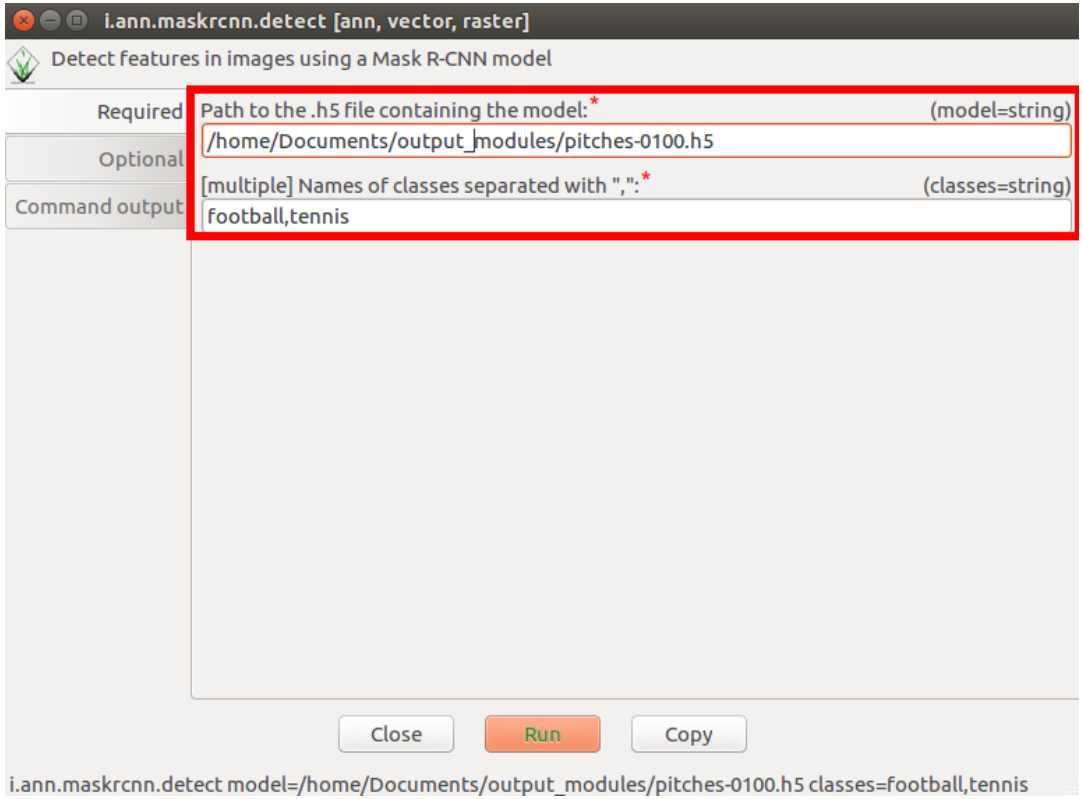

i.ann.maskrcnn.detect

Postup práce modulu

- naplnění natrénovanými váhami
- detekce pro každý obrázek

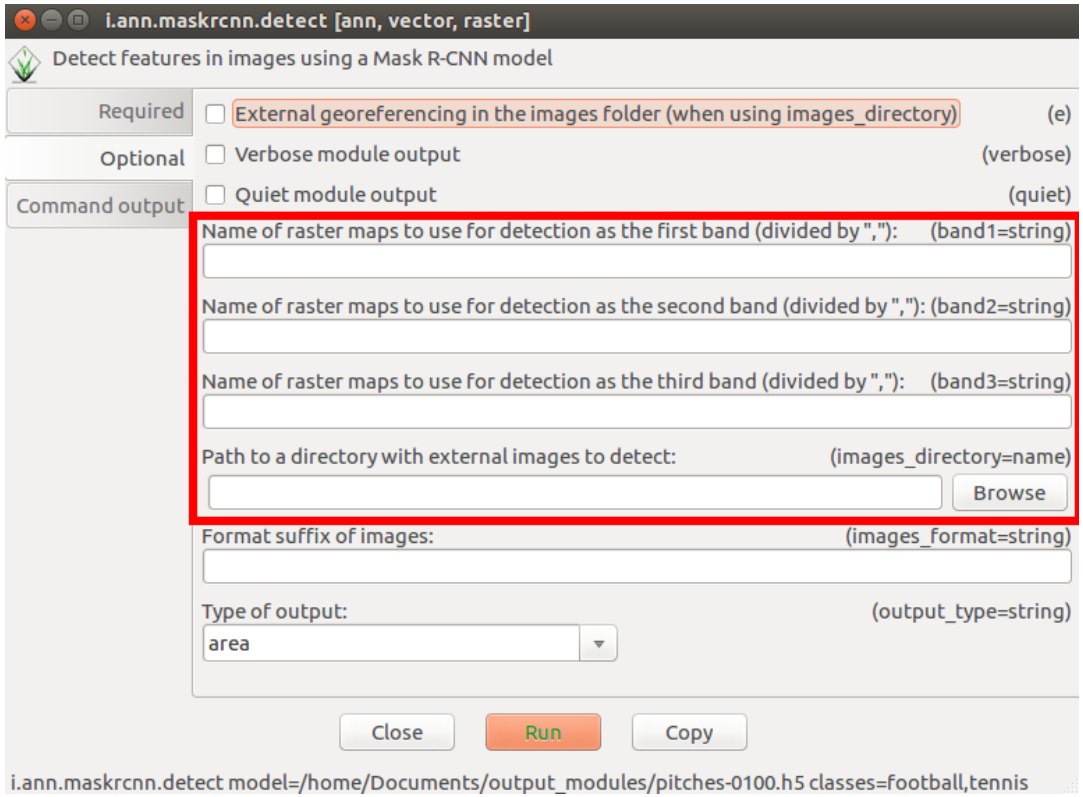

i.ann.maskrcnn.detect

Postup práce modulu

- naplnění natrénovanými váhami
- detekce pro každý obrázek
- vektorizace

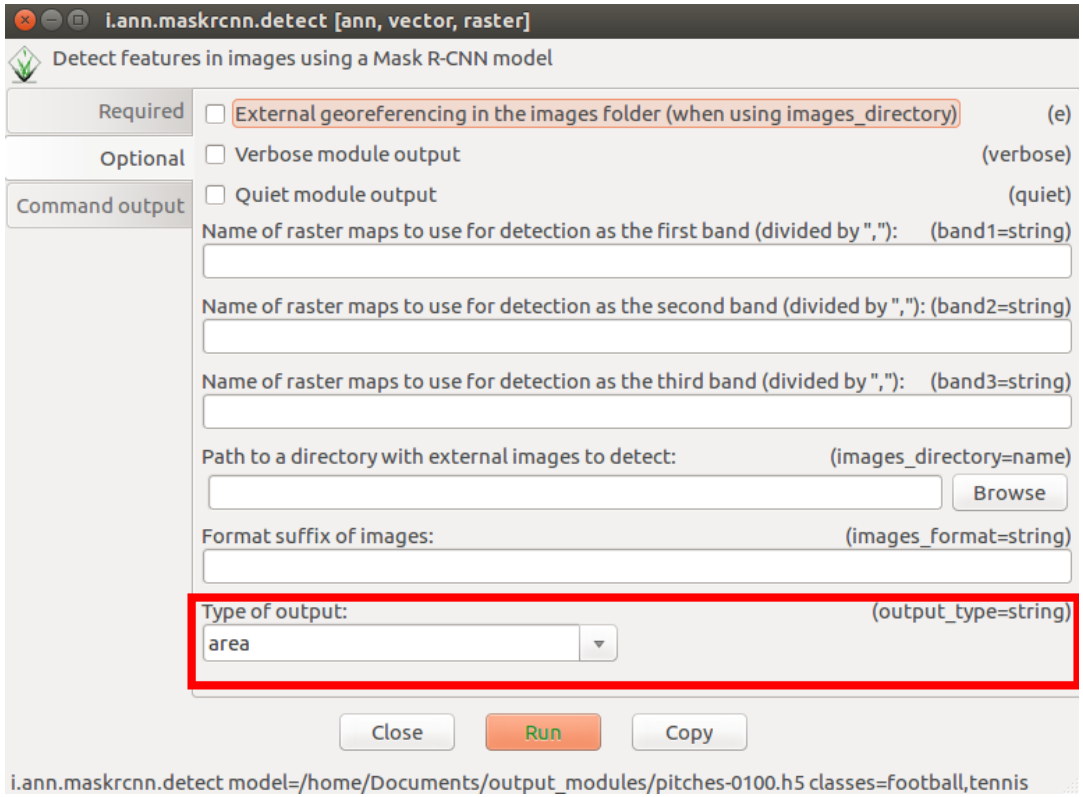

Výsledky

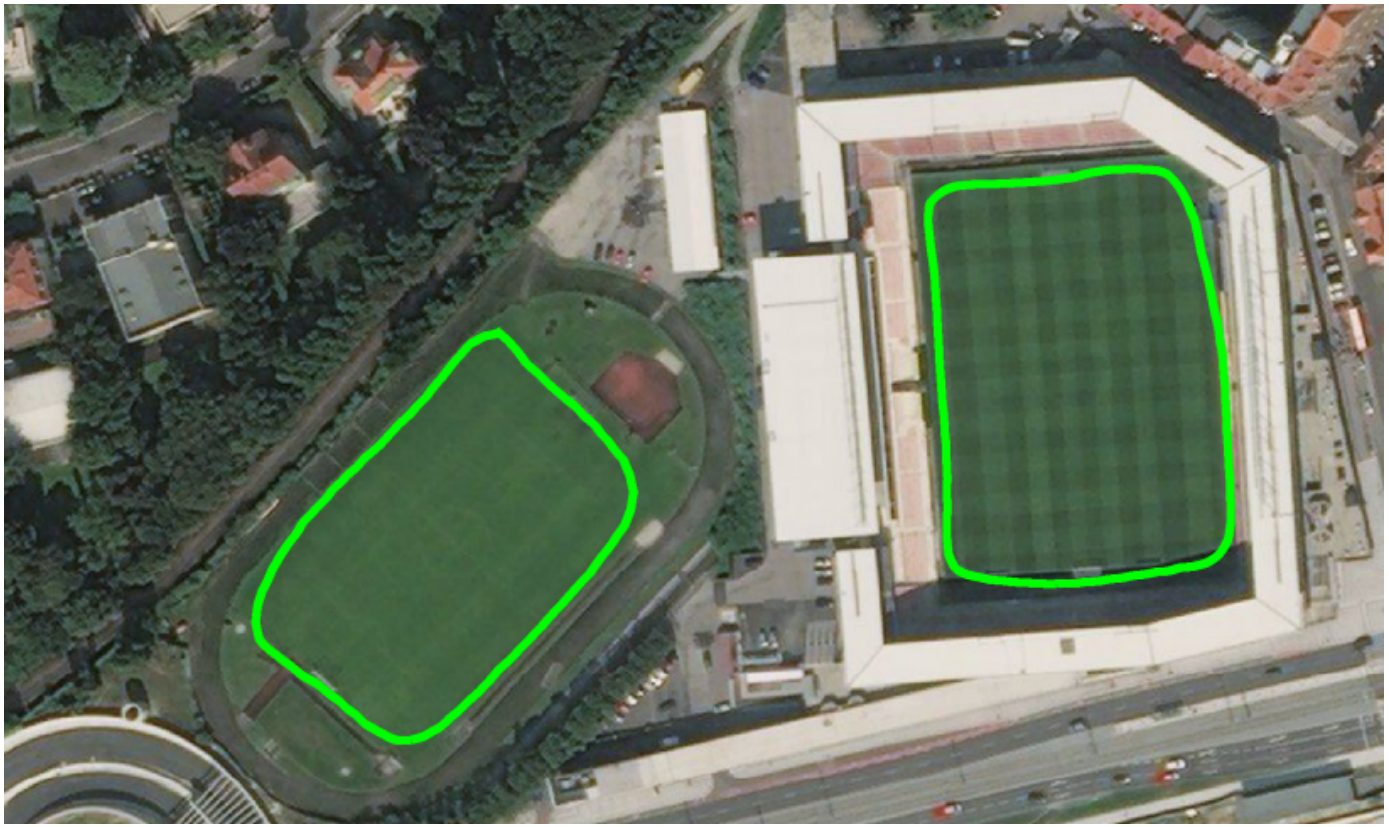

Obrázek: ztrátová funkce 0.96, 54000 trénovacích obrázků

Výsledky

Obrázek: ztrátová funkce 0.96, 54000 trénovacích obrázků

Výsledky

Obrázek: ztrátová funkce 0.96, 54000 trénovacích obrázků

Výsledky

Obrázek: ztrátová funkce 0.96, 54000 trénovacích obrázků

Výsledky

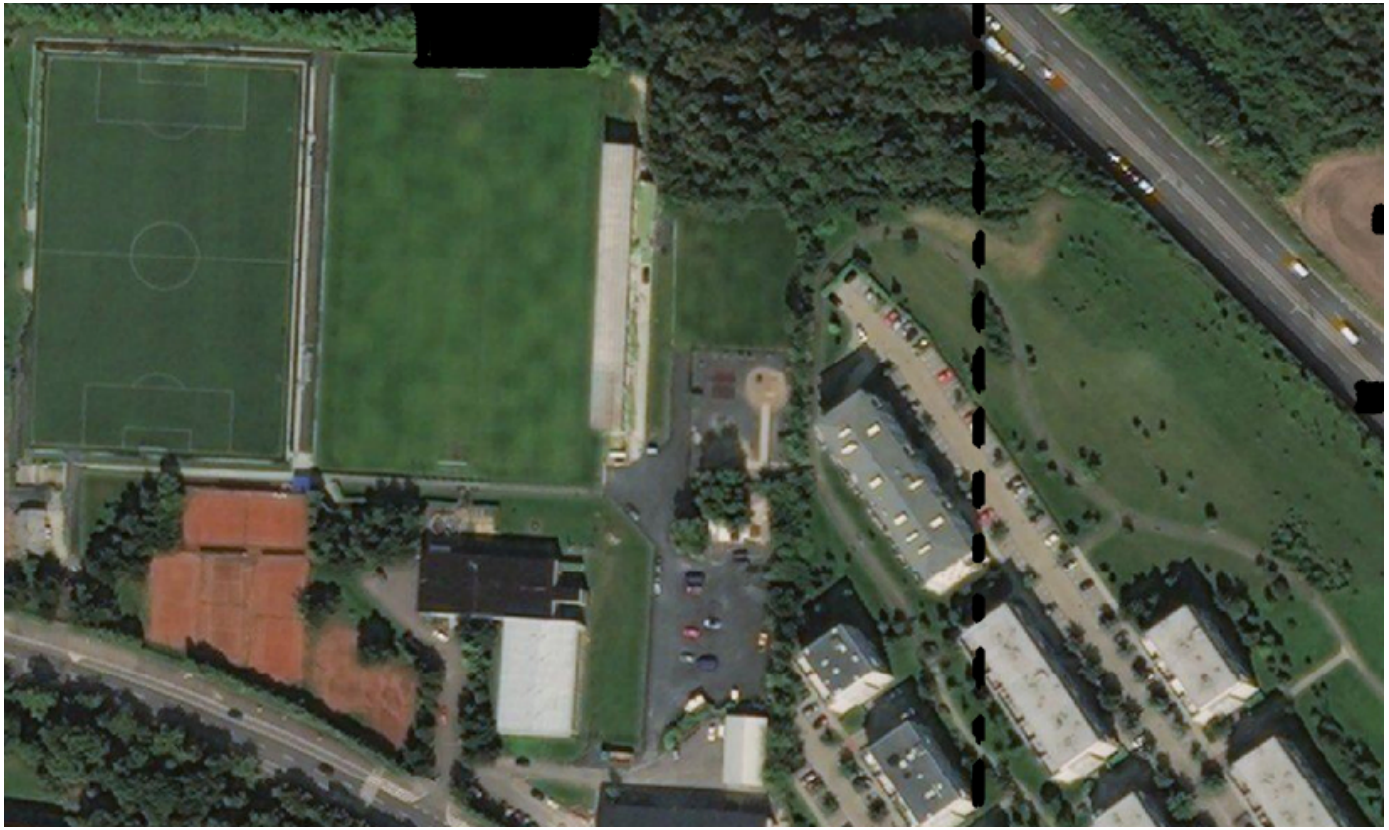

Obrázek: epocha 1, ztrátová funkce 35.01, 2400 trénovacích obrázků

Výsledky

Obrázek: epocha 10, ztrátová funkce 5.87, 2400 trénovacích obrázků

Výsledky

Obrázek: epocha 50, ztrátová funkce 1.36, 2400 trénovacích obrázků

Výsledky

Obrázek: epocha 150, ztrátová funkce 0.63, 2400 trénovacích obrázků

Výsledky

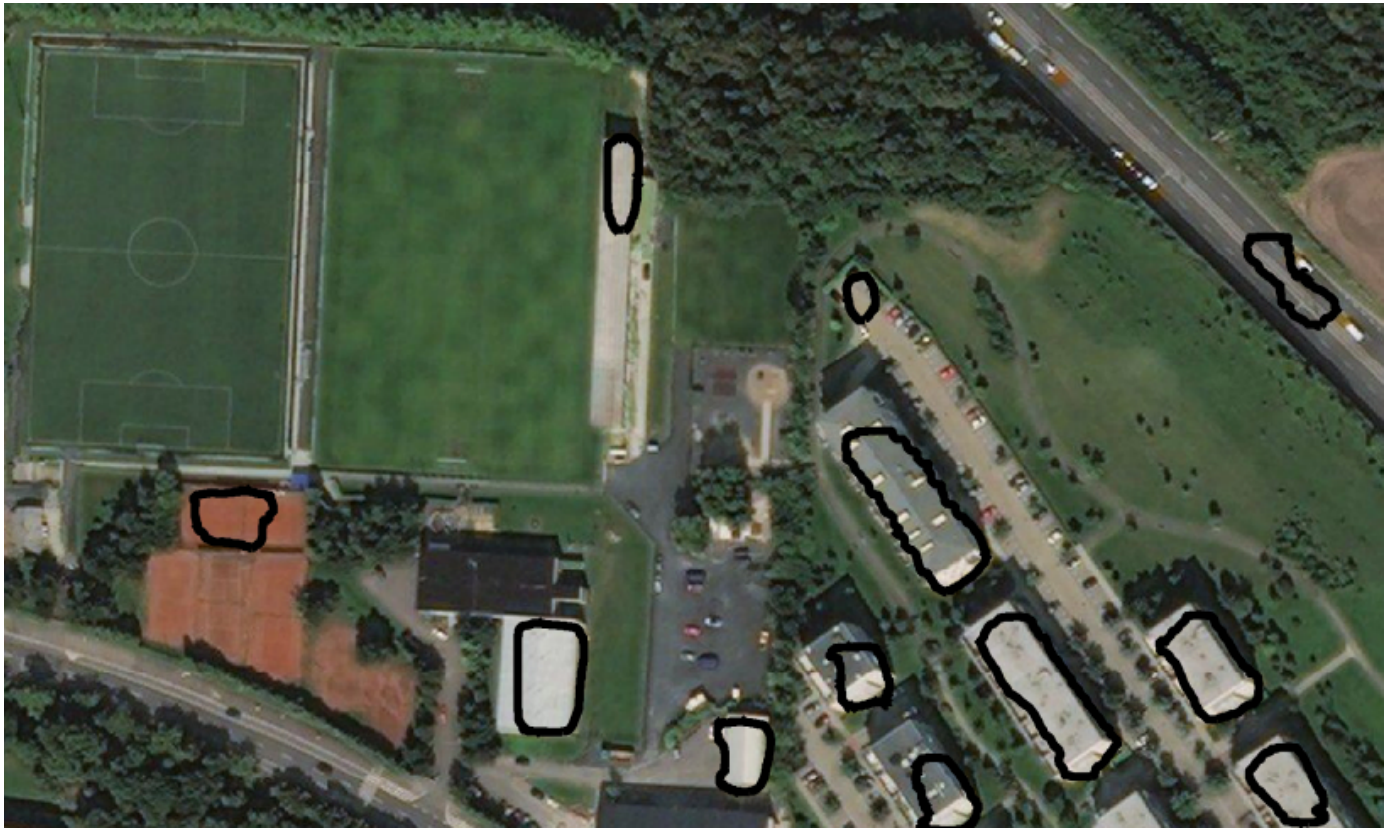

Obrázek: epocha 180, ztrátová funkce 0.50, 2400 trénovacích obrázků

Závěr

- zdrojový kód
  - `https://github.com/ctu-geoforall-lab-projects/dp-pesek-2018`
  - `https://svn.osgeo.org/grass/grass-addons/grass7/imagery/i.ann.maskrcnn/`
- instalace pomocí příkazu
  `g.extension extension=i.ann.maskrcnn`
- další vývoj
  - `https://github.com/ctu-geoforall-lab/i.ann.maskrcnn`
  - multispektrální rastry
  - učení na rastrech importovaných v prostředí GRASS
  - další architektury

Zdroje

[1] https://www.analyticsvidhya.com/blog/2016/04/deep-learning-computer-vision-introduction-convolution-neural-networks/
[2] RUSSAKOVSY, Olga et al. ImageNet Large Scale Visual Recognition Challenge. International Journal of Computer Vision IJCV. 2015, 115, n. 3, pp. 211–252.
[3] http://cs231n.stanford.edu/
[4] HE, Kaiming et al. Mask R-CNN. In: International Conference on Computer Vision (ICCV). 2017.
[5] GIRSHICK, Ross. Fast R-CNN. In: International Conference on Computer Vision (ICCV). 2015.

Děkuji za pozornost.

Reakce na otázky oponenta

Jaké jsou výhody/nevýhody užití neuronových sítí namísto klasických postupů?

Výhody:

Nevýhody:

Reakce na otázky oponenta

Jaké jsou výhody/nevýhody užití neuronových sítí namísto klasických postupů?

Výhody:

- přesnost

Nevýhody:

Reakce na otázky oponenta

Jaké jsou výhody/nevýhody užití neuronových sítí namísto klasických postupů?

Výhody:

- přesnost
- minimalizovaná potřeba vytvářet ad hoc řešení

Nevýhody:

Reakce na otázky oponenta

Jaké jsou výhody/nevýhody užití neuronových sítí namísto klasických postupů?

Výhody:

- přesnost
- minimalizovaná potřeba vytvářet ad hoc řešení
- obecnost

Nevýhody:

Reakce na otázky oponenta

Jaké jsou výhody/nevýhody užití neuronových sítí namísto klasických postupů?

Výhody:

- přesnost
- minimalizovaná potřeba vytvářet ad hoc řešení
- obecnost

Nevýhody:

- výpočetní náročnost

Reakce na otázky oponenta

Jaké jsou výhody/nevýhody užití neuronových sítí namísto klasických postupů?

Výhody:

- přesnost
- minimalizovaná potřeba vytvářet ad hoc řešení
- obecnost

Nevýhody:

- výpočetní náročnost
- časová náročnost

Reakce na otázky oponenta

Jaké jsou výhody/nevýhody užití neuronových sítí namísto klasických postupů?

Výhody:

- přesnost
- minimalizovaná potřeba vytvářet ad hoc řešení
- obecnost

Nevýhody:

- výpočetní náročnost
- časová náročnost
- potřeba rozsáhlých trénovacích dat

Reakce na otázky oponenta

Jaké jsou výhody/nevýhody užití neuronových sítí namísto klasických postupů?

Výhody:

- přesnost
- minimalizovaná potřeba vytvářet ad hoc řešení
- obecnost

Nevýhody:

- výpočetní náročnost
- časová náročnost
- potřeba rozsáhlých trénovacích dat
- odvážným štěstí nepřeje vždy

Reakce na otázky oponenta

Implementoval jste modifikace využitého software i zpět do zdrojů?

Ano:

Ne:

Reakce na otázky oponenta

Implementoval jste modifikace využitého software i zpět do zdrojů?

Ano:

- GRASS GIS

Ne:

Reakce na otázky oponenta

Implementoval jste modifikace využitého software i zpět do zdrojů?

Ano:

- GRASS GIS

Ne:

- GRASS GIS

Reakce na otázky oponenta

Implementoval jste modifikace využitého software i zpět do zdrojů?

Ano:

- GRASS GIS

Ne:

- GRASS GIS
- Matterport, Inc.

Reakce na otázky oponenta

Implementoval jste modifikace využitého software i zpět do zdrojů?

Ano:

- GRASS GIS

Ne:

- GRASS GIS
- Matterport, Inc.

Reakce na otázky oponenta

Implementoval jste modifikace využitého software i zpět do zdrojů?

Ano:

- GRASS GIS

Ne:

- GRASS GIS
- Matterport, Inc.

Reakce na otázky oponenta

Implementoval jste modifikace využitého software i zpět do zdrojů?

Ano:

- GRASS GIS

Ne:

- GRASS GIS
- Matterport, Inc.
- potřeba rozsáhlých trénovacích dat

Reakce na otázky oponenta

Implementoval jste modifikace využitého software i zpět do zdrojů?

Ano:

- GRASS GIS

Ne:

- GRASS GIS
- Matterport, Inc.
- potřeba rozsáhlých trénovacích dat
- odvážným štěstí nepřeje vždy

Reakce na otázky oponenta

Shledáváte některé části svého kódu natolik obecnými, aby mohly být využiti i při vývoji dalších podobných nástrojů?

Reakce na otázky oponenta

Shledáváte některé části svého kódu natolik obecnými, aby mohly být využiti i při vývoji dalších podobných nástrojů?

Ano.

Reakce na otázky oponenta

V textu práce jste zmínil a rozebíral podezřelé chování modulů skýtajících lepší výsledky při vyšší ztrátové funkci. Můžete tento případ ještě rozvést?

Možné příčiny:

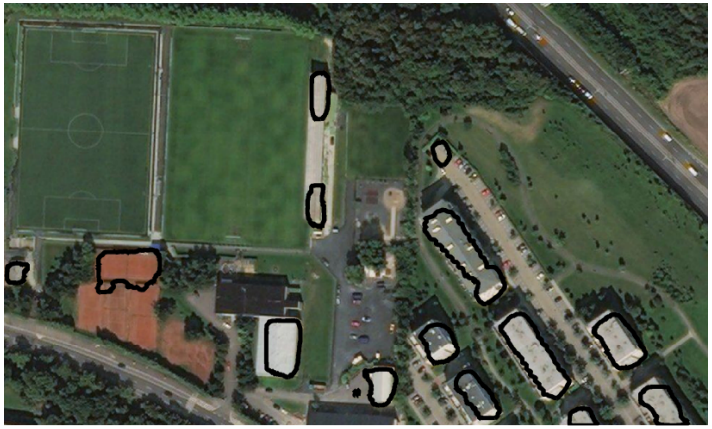

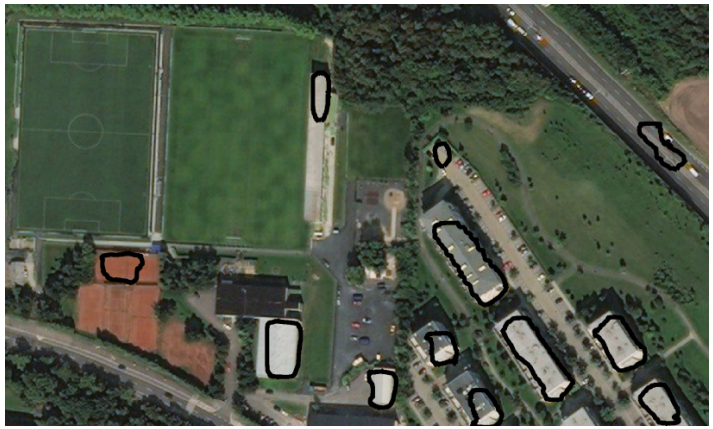

Reakce na otázky oponenta

V textu práce jste zmínil a rozebíral podezřelé chování modulů skýtajících lepší výsledky při vyšší ztrátové funkci. Můžete tento případ ještě rozvést?

Možné příčiny:

- přeoptimalizace

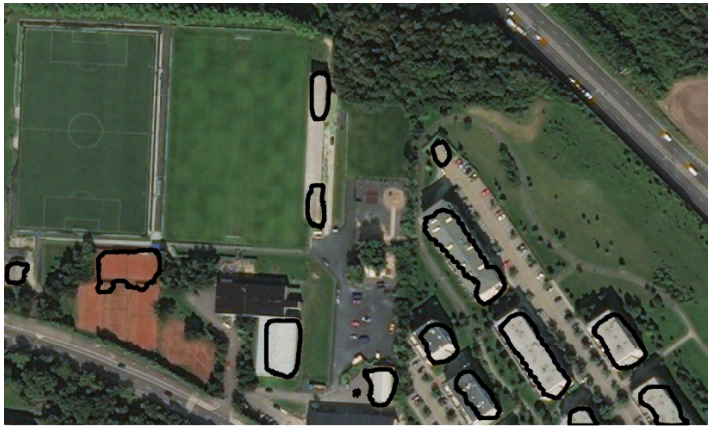

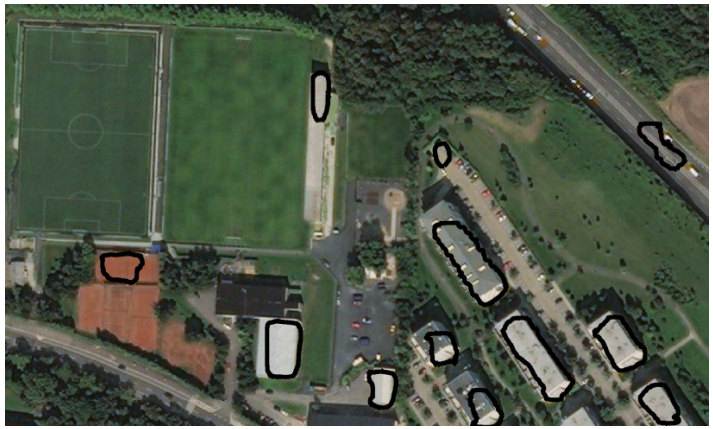

Reakce na otázky oponenta

V textu práce jste zmínil a rozebíral podezřelé chování modulů skýtajících lepší výsledky při vyšší ztrátové funkci. Můžete tento případ ještě rozvést?

Možné příčiny:

- přeoptimalizace
- lokální odchylka

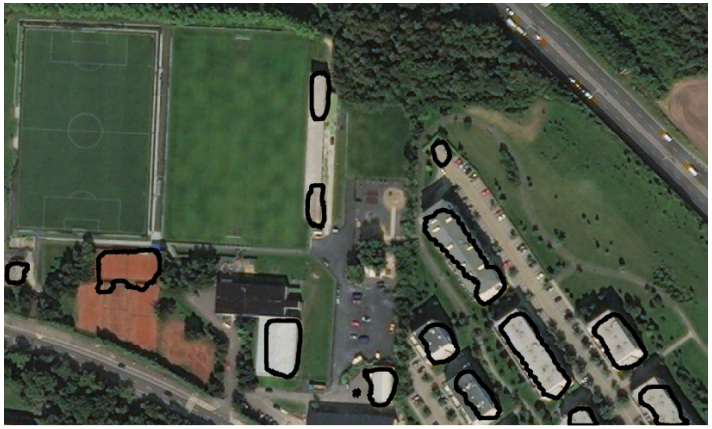

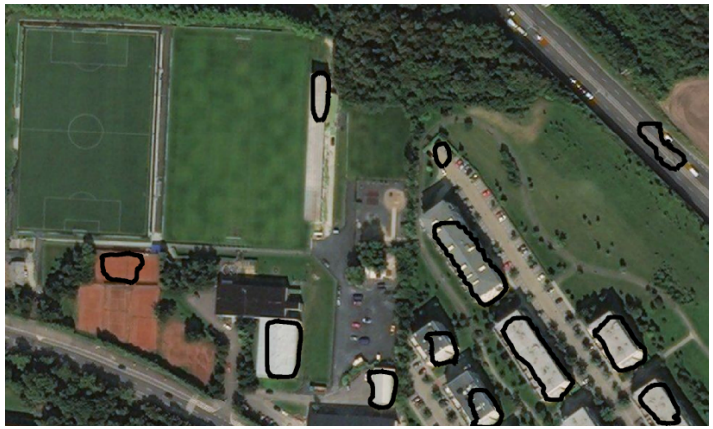

Reakce na otázky oponenta

V textu práce jste zmínil a rozebíral podezřelé chování modulů skýtajících lepší výsledky při vyšší ztrátové funkci. Můžete tento případ ještě rozvést?

Možné příčiny:
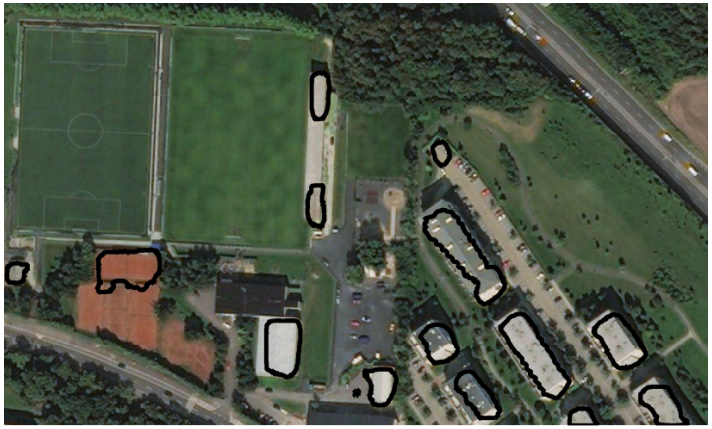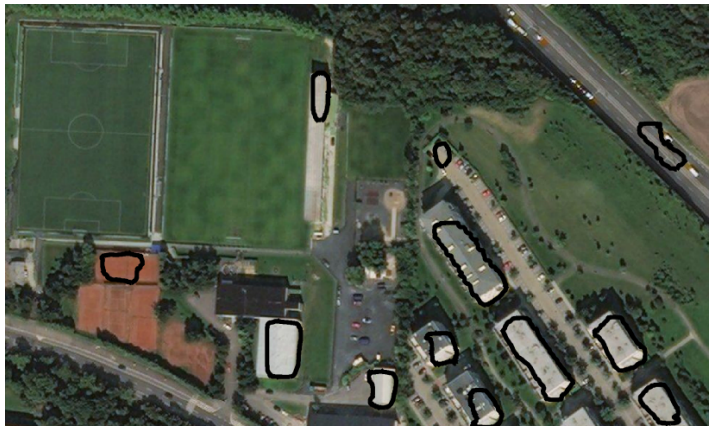
- přeoptimalizace
- lokální odchylka
- nedostatečná data